

2025년도 머신러닝 개인 프로젝트

AI개발 수행내역서

과제명	서울시 청년 데이터 기반 사회적 고립 위험 예측 모델 개발 및 시각화
담당자	신민서

2025년 12 월 30 일

AI개발 수행내용

사업과제 : 서울시 청년 고립·은둔 현황 조사 기반 AI 예측 모델 개발 및 웹 시각화 시스템 구축

1. 개요 및 현황

1.1 추진배경 및 목적

- 1인가구 급증 및 사회적 안전망 약화로 청년층의 고립 위험이 구조적으로 심화되고 있으며, 고독사 등 사회적 문제로 연결될 우려가 있음
- 최근 '일자리 밖' 청년이 160만 명에 육박하는 등 고용 부진과 장기 미취업이 청년의 자존감 하락 및 사회적 단절(은둔)을 촉발하는 핵심 요인으로 작용
- 본 과제에서는 청년 실태 데이터를 활용해 고립·은둔 위험군을 조기에 판별할 수 있는 AI 예측 모델을 개발하여, 선제적 발굴 및 맞춤형 지원 정책의 근거를 마련하고자 함

1.2 과제 범위

과제구분		내용
AI	AI 기반 고립·은둔 위험군 예측 모델 개발	원시 데이터(서울시 실태조사 5,513명) 수집 및 데이터셋 구축
		데이터 전처리(결측치, 이상치, 인코딩) 및 상관관계 분석 (EDA 도구 활용)
		예측 모델 선정(Random Forest, Logistic Regression 등) 및 학습
		Accuracy, ROC-AUC, Precision, Recall, F1-Score 평가지표를 활용한 모델 성능 평가
시각화	예측 결과 시각화 및 웹 시스템 구축	예측 실행 웹앱 프로토타입 구축 (Streamlit 활용)
		개인별 위험도 점수 및 위험 수준(고/중/저) 시각화
		모델 성능(ROC 곡선, 혼동행렬) 및 특성 중요도(Feature Importance) 시각화
테스트	모델 검증 및 시스템 테스트	테스트 데이터셋(20%)을 활용한 일반화 성능 검증
		웹 애플리케이션 기능 테스트 및 사용성 점검

1.3 과제 추진 방법

1) 구축 대상 선정 기준

- 데이터 접근성 및 신뢰성
 - 서울시 공식 조사기관에서 수집한 신뢰할 수 있는 청년 표본 데이터 활용
 - 5,513명의 대규모 표본으로 통계적 신뢰성 및 모델 일반화 가능성 확보
 - 전문가 상담 및 진단을 통해 고립·은둔 여부를 객관적으로 분류한 라벨 데이터 확보

○ 모델링 효율성

- **클래스 불균형(고위험 8.8% vs 저위험 91.2%)**이 존재하지만 극단적이지 않아 모델 최적화(SMOTE, Class Weight 등) 용이
- 결측치가 특정 변수에 집중 되어 있어 일관된 처리 방안 수립 및 적용 가능
- 변수 간 다중공선성이 낮아, 독립변수의 개별 영향력을 명확히 파악하는 안정적인 모델 학습 기대


○ 실무 활용도 및 경제성

- 청년 고립·은둔 문제 해결을 위한 정책 입안 및 현장 개입의 과학적 근거 제공
- 상담 전문가의 **의사결정 지원(Decision Support)**으로 조기 발굴 및 개입 효율성 향상
- 고위험군 자동 선별(Screening)을 통한 비용 절감 및 사각지대 해소 효과

2) AI 예측 분석모델 적용 대상

구분	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
청년 고립·은둔	- 고립·은둔 여부 라벨 데이터 (5,513명) - 심리·사회·경제 특성 - 인구통계 정보 (성별, 나이 등) - 가구 특성 및 주거 환경	- A11 (교류 빈도) - A6 (사회경제 수준) - A1 (노동여부) - DQ2 (직업) - A5 (식사 횟수) - SQ2 (나이)	- 개별 고립·은둔 위험도(Risk Score) 산출 - 고위험군 조기 발굴 및 등급화(High/Mid/Low) - 주요 변수(식사 횟수, 교류 빈도 등)와 고립 간의 상관관계 분석

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

2. 데이터 수집 및 개요

2.1 데이터 출처

- 출처: <https://data.seoul.go.kr/dataList/OA-22347/F/1/datasetView.do>
- 대상: 서울 거주 만 19~39세 청년 및 고립·은둔 청년 당사자
- 목적: 청년의 생활 실태 및 고립·은둔 위험 요인을 분석하여 AI 기반 예측 모델 개발

2.2 데이터 구성 및 클래스 분포

- 총 데이터 수량: 5,513명
- 저위험군 (미해당, 0): 5,027명 (91.2%)
- 고위험군 (고립·은둔, 1): 486명 (8.8%)

분석

고위험군이 전체의 약 8.8%를 차지하여 클래스 불균형(Imbalanced Data)이 존재함. 이를 해결하기 위해 모델 학습 시 Class Weight 조정 및 F1-Score 중심의 성능평가를 수행함

2.3 Features 및 전처리 구조

청년의 고립·은둔에 영향을 미치는 변수를 인구통계, 심리상태, 경제활동, 생활습관 등으로 분류하여 분석

- 전처리 전: 21개 변수 (결측치 34,434개 존재)
- 전처리 후: 44개 변수 (원-핫 인코딩 적용 후, 결측치 0개)

```
>> 변수 타입 분류:
● 명목형(순서 없음): A1, DQ2, DQ3, DQ5, B5_1, B7, B8 → 원-핫 인코딩 필수
● 서수형(순서 있음): SQ1, SQ2_X, SQ6_R, A5, A6, B2_R, A11 → 그대로 사용

● 더미형(다중선택): A4_1~A4_7 → 0/1 그대로

[✓] SQ1 | 결측치: 0 ( 0.00%)
[✓] A1 | 결측치: 0 ( 0.00%)
[✓] SQ2_X | 결측치: 0 ( 0.00%)
[✓] SQ6_R | 결측치: 0 ( 0.00%)
[✓] A5 | 결측치: 80 ( 1.45%)
[✓] A6 | 결측치: 80 ( 1.45%)
[✓] B2_R | 결측치: 160 ( 2.90%)
[✓] DQ2 | 결측치: 80 ( 1.45%)
[✓] DQ3 | 결측치: 159 ( 2.88%)
[✓] DQ5 | 결측치: 0 ( 0.00%)
[✗] DQ5_1 | 결측치: 2011 (36.48%)
[✓] A11 | 결측치: 159 ( 2.88%)
[✗] A4_1 | 결측치: 679 (12.32%)
[✗] A4_2 | 결측치: 5176 (93.89%)
[✗] A4_3 | 결측치: 5354 (97.12%)
[✗] A4_4 | 결측치: 5448 (98.82%)
[✗] A4_5 | 결측치: 5478 (99.37%)
[✗] A4_6 | 결측치: 4318 (78.32%)
[✗] A4_7 | 결측치: 5252 (95.27%)
[✓] B7 | 결측치: 0 ( 0.00%)
[✓] B8 | 결측치: 0 ( 0.00%)
```

1) 변수 타입별 처리 전략

변수타입	처리 방식	해당 변수
명목형 (순서 없음)	원-핫 인코딩 (One-Hot Encoding)	A1(노동여부), DQ2(직업), DQ3(혼인상태), DQ5(주택형태), B8(식사횟수) 등
서수형 (순서 있음)	수치형 유지 (Label Encoding)	SQ1(성별), SQ2(나이), A5(경제수준), A11(교류빈도)
더미형 (다중선택)	0/1 그대로 사용	A4_1 ~ A4_7 (소득원 정보)

2) 결측치(Missing Value) 처리 내역

- 소득원(A4): 미가입 항목은 '없음(0)'으로 간주하여 대체
- 주요 변수(A5, A6, A11 등): 데이터 분포의 안정성을 위해 **중앙값(Median)**으로 대체
- 범주형 변수(DQ2(직업), DQ3(혼인상태)): 최빈값(Mode)으로 대체하여 데이터 왜곡 최소화

4.1 소득원 결측치 처리: 0으로 대체

4.2 결측치 처리 (수치형/범주형 구분):

- ✓ A5: 중앙값 3.00 으로 대체
- ✓ A6: 중앙값 2.00 으로 대체
- ✓ B2_R: 중앙값 2.00 으로 대체
- ✓ DQ2: 중앙값 1.00 으로 대체
- ✓ DQ3: 중앙값 2.00 으로 대체
- ✓ DQ5_1: 중앙값 1.00 으로 대체
- ✓ A11: 중앙값 5.00 으로 대체

4.3 원-핫 인코딩 (명목형 변수):

대상 변수: DQ2, DQ3, DQ5, A1, B8, B2_R, B7

3. 데이터 학습 및 모델정의

3.1 데이터 분할 및 스케일링

1) Train/Test Split (학습 데이터 분할)

모델의 일반화 성능 검증을 위해 전체 데이터를 학습(80%) : 테스트(20%) 비율로 분할 하였으며, 클래스 불균형을 유지하기 위해 Stratified Split 방식을 적용함.

구분	샘플 수	고위험군 수	고위험군 비율
학습 데이터 (Train)	4,410명	389명	8.8%
테스트 데이터 (Test)	1,103명	97명	8.8%
합계	5,513명	486명	8.8%

2) 데이터 스케일링 (StandardScaler)

변수 간 스케일 차이로 인한 학습 편향을 방지하기 위해 StandardScaler를 적용함.

- 학습 데이터: fit() 수행하여 평균(mean)과 표준편차(std) 계산
- 테스트 데이터: transform()만 적용하여 데이터 누수(Data Leakage) 방지

3.2 모델 학습 및 하이퍼파라미터 튜닝

1) 후보 모델 선정 및 학습

고립·은둔 위험군 예측을 위해 2가지 알고리즘을 비교 학습함

모델명	알고리즘 유형
Logistic Regression	선형 분류 모델 (해석 가능성 높음)
Random Forest	앙상블 모델 (비선형 패턴 포착)

2) 하이퍼파라미터 튜닝 (GridSearchCV)

Random Forest 모델의 성능 최적화를 위해 **GridSearchCV(5-Fold Cross Validation)**를 수행하여 최적 파라미터를 탐색함

- 최적 F1-Score: 0.5078
- 튜닝 기준: Precision과 Recall의 균형을 고려한 F1-Score 최대화

파라미터	최적값	의미
n_estimators	150	의사결정나무 개수
max_depth	20	트리 최대 깊이
min_samples_split	10	노드 분할 최소 샘플 수
min_samples_leaf	2	리프 노드 최소 샘플 수

3.3 모델 성능 비교

1) 최종 성능 평가 (테스트 데이터 기준)

3가지 모델(로지스틱 회귀, 랜덤 포레스트 기본, 랜덤 포레스트 최적화)을 학습한 후 테스트 데이터 (1,103명)로 평가한 결과는 다음과 같음

모델명	Accuracy	ROC-AUC	Precision	Recall	F1-Score
Logistic Regression	0.786	0.846	0.254	0.742	0.379
Random Forest (Basic)	0.928	0.855	0.765	0.268	0.397
Random Forest (Best - F1 Optimized)	0.904	0.873	0.464	0.598	0.523

2) 모델별 특성 분석

- **Logistic Regression:** Recall이 높아(74.2%) 고위험군을 많이 탐지하지만 Precision(정밀도)가 낮아 오탐 (False Positive)이 많음. 스크리닝(1차 선별)용으로 적합
- **Random Forest (Basic):** Accuracy와 Precision은 우수하나 Recall이 낮아(26.8%) 고위험군의 73%를 놓침
- **Random Forest (Best - F1 Optimized):** Precision-Recall(정밀도) 균형이 가장 우수하며 ROC-AUC(재현율)도 최고(0.873) -> (최종 선정 모델)

3.4 특성 중요도 분석 (Feature Importance)


최적화된 Random Forest 모델을 통해 고립·은둔에 가장 큰 영향을 미치는 변수를 분석한 결과, 상위 10개 변수는 다음과 같음

순위	변수명	중요도	해석
1	A11(교류 빈도)	0.155	타인과의 만남 횟수 ↓ → 고립 위험 ↑
2	A6(사회경제 수준)	0.145	주관적 경제 수준 ↓ → 고립 위험 ↑
3	A1_3(노동 여부)	0.119	실업/비경제활동 → 고립 위험 ↑
4	DQ2_10.0(직업 상태)	0.069	특정 직업군 → 고립 위험
5	A5(식사 횟수)	0.063	식사 횟수 ↓ → 고립 위험 ↑
6	SQ6_R(거주 기간)	0.041	단기 거주 → 지역 소속감 ↓
7	SQ2_X(나이)	0.034	특정 연령대 → 고립 취약
8	DQ3_2.0(주거 형태)	0.032	특정 주거 유형 → 고립 위험
9	A4_1(소득원)	0.030	소득원 부재 → 경제적 고립
10	DQ5_4(가족 지원)	0.021	가족 지원 부족 → 고립 위험 ↑

4. 모델 평가 및 분석 결과 시각화

4.1 모델 성능 종합 평가 (ROC Curve Comparison)

모델별 성능을 비교하기 위해 ROC(Receiver Operating Characteristic) 곡선과 AUC(Area Under Curve) 점수를 시각화함




<분석 결과>

- Random Forest (Best) 모델의 AUC가 0.873으로 가장 높게 나타남.
- Logistic Regression (AUC 0.846) 대비 곡선이 왼쪽 상단(좌상향)에 더 근접하여, 예측 정확도와 안정성이 우수함을 입증함.
- 점선(Random Guess, AUC 0.5)과 확연한 차이를 보이며 유의미한 예측 모델임이 확인됨.

4.2 혼동행렬 분석 (Confusion Matrix)


테스트 데이터(1,103명)에 대한 실제값과 예측값의 일치 여부를 혼동행렬로 시각화하여 정밀하게 분석



- Logistic Regression (좌측): 고립(Isolated)을 72명 잘 맞췄으나, 일반(Normal)을 고립으로 잘못 예측한 경우(오탐, FP)가 211명으로 많음 → 과잉 탐지 경향
- Random Forest Best (우측): 오탐(FP)이 67명으로 대폭 감소(211→67)하였으며, 고립군 예측(TP)도 58명으로 준수한 수준을 유지함
- 결론: 오탐을 줄여 실제 현장 개입의 효율성을 높이기 위해 Random Forest 모델이 더 적합함

4.3 핵심 영향 요인 분석 (Feature Importance)


Random Forest 모델이 고립·은둔을 판단할 때 가장 중요하게 고려한 **상위 10개 변수 (Top 10 Features)**를 도출함



- 1순위 A11 (교류 빈도): 타인과의 만남 횟수가 가장 결정적인 요인으로 나타남
- 2순위 A6 (사회경제 수준): 주관적인 경제 수준 인식이 고립에 큰 영향을 미침
- 3순위 A1_3 (노동 여부): 경제활동(취업) 여부가 사회적 단절과 직결됨
- 시사점: 단순히 '성격'의 문제가 아니라 **경제적 요인(A6, A1)**과 **사회적 관계망(A11)**이 고립을 유발하는 구조적 원인임을 데이터로 입증함

4.4 고립·은둔 집단 특성 분석 (A11 분포)

가장 중요한 변수인 **A11(교류 빈도)**의 데이터 분포를 고위험군(Isolated)과 저위험군(Normal)으로 나누어 비교함




- Red (Isolated): 고위험군은 A11 값이 '0' 근처에 극도로 집중되어 있음. (거의 만나지 않음)
- Blue (Normal): 저위험군은 A11 값이 0보다 크고 넓게 퍼져 있어, 비교적 활발하고 다양한 교류 패턴을 보임
- 해석: "교류가 거의 없는 상태(0)"가 고립·은둔을 식별하는 가장 강력한 **시그널(Signal)**임이 시각적으로 확인됨

5. 웹기반 예측 시스템 (Streamlit Dashboard)

5.1 시스템 개요

- 청년 고립·은둔 위험군을 실시간으로 진단하고 시각화하는 웹기반 대시보드 시스템을 Streamlit 프레임워크로 개발함
- 사용자 입력 없이도 모든 분석 결과를 한눈에 확인할 수 있으며, 특히 개인별 위험도 예측 기능은 상담 현장에서 직접 활용 가능



📁 프로젝트 개요

🎯 목표

서울시의 고립·은둔 위험군을 머신러닝으로 예측하고 영향 요인을 분석합니다.

📊 데이터

- 출처: 서울시 고립·은둔 실태 조사
- 샘플: 5,513명
- 특성: 44개

🧠 모델

- RandomForest (최고 성능) - 높은 정확도, 특성 중요도 분석
- LogisticRegression - 해석성 우수, 확률 기반 예측

🔍 주요 기능

- 👤 개인 위험도 진단 - 사용자 입력으로 위험도 예측
- 📊 모델 성능 - 상세한 성능 비교
- 📈 특성 분석 - 핵심 영향 요인 파악
- 🖼️ 시각화 - ROC Curve, Confusion Matrix 등

⚡ 빠른 참조

타겟 변수:

- 고위험군 (1)
- 저위험군 (0)

평가 지표:

- Accuracy
- ROC-AUC
- Precision
- Recall
- F1-Score

사용 변수:

- A1: 노동 여부
- DQ2: 직업
- A11: 교류 횟수
- A5: 식사 횟수
- A6: 사회경제 수준
- SQ6_R: 동거 인원

5.2 핵심 입력 변수 선정 (사용자 편의성 고려)

AI 모델은 총 44개의 정밀한 변수를 학습하여 높은 예측 성능을 확보하였으나, 실제 대국민 웹 서비스(Web App)에서는 사용자의 입력 부담을 줄이고 접근성을 높이기 위해 특성 중요도(Feature Importance)가 높은 상위 6개 핵심 변수를 선별하여 입력값으로 활용함.

순번	변수명	변수 설명	입력 방식 (UI)
1	A11	교류 빈도(타인과의 만남 횟수)	슬라이더 / 선택지
2	A6	사회경제 수준(주관적 인식)	5점 척도 선택
3	A1	노동 여부(지난주 경제활동 유무)	예 / 아니오
4	DQ2	직업 상태(현재 고용 형태)	드롭다운 선택
5	A5	식사 횟수(일 평균 끼니 수)	숫자 입력 (0~3회)
6	SQ2	나이(만 나이)	숫자 입력

5.3 예측 서비스 프로세스

- 사용자 입력: 웹페이지에서 위 6가지 핵심 질문에 답변
- AI 모델 추론: 입력되지 않은 나머지 변수는 전체 데이터셋의 **대표값(최빈값/중앙값)**으로 자동 보정하여 모델에 주입
- 결과 산출: 전체 44개 변수 기반으로 학습된 모델이 고립·은둔 위험 확률(%) 계산
- 피드백 제공: 위험도 등급(고/중/저) 및 맞춤형 지원 정책 안내

5.4 개인 위험도 예측 (Prediction)

- 목적: 실제 상담 현장에서 신규 청년의 고립 위험도를 즉시 진단

개인 위험도 진단 6Q

6가지 주요 정보를 입력하면 AI가 고립-은둔 위험도를 판정합니다.

- **저위험군**: 사회활동이 활발하고 건강한 생활습관
- **중위험군**: 일부 위험 요소 존재 - 개선 필요
- **고위험군**: 사회적 고립 경향이 높음 - 전문가 상담 권장

나이 (연령대)

SQ2_K: 나이 (5세 단위 연령대)

- ☐ 만 19~24세
☒ 만 25~29세
☐ 만 30~34세
☐ 만 35~39세

경제 활동

A1: 한 주 동안 1시간 이상의 노동 여부

☒ 일을 하였다

DQ2: 현재 직업

정규직(상용직)

사회 활동

A11: 지난 2주 동안 사람들의 교류 횟수 ★

0

교류 횟수

0회

생활 습관

A5: 하루 동안의 식사 횟수

4끼 이상 🍴🍴🍴🍴

A6: 자신의 사회경제적 수준

매우 부족함 ●

가구 구성

SQ6_R: 함께 살고 있는 사람 수 (자신 포함)

3

👤👤👤 (3명)

동거 인원

3명

 위험도 판정하기

💡 권고사항 및 해석

● 고위험군 (고위험 확률: 55.7%)

현재 상태: 전문 기관 상담이 필요합니다 🚨


권고 사항:

- 🏠 서울시 고립·은둔 관련 부서에 연락하기
- 👨‍👩‍👧 가족이나 신뢰할 수 있는 사람과 대화하기
- 🏥 정신 건강 검진 받기
- 📅 직업 훈련 또는 상담 프로그램 참여
- 🌐 사회 복귀 프로그램 정보 수집

주의: 이 진단은 의료 전문가의 진단을 대체할 수 없습니다.

📊 위험도 시각화

고립·은둔 위험도 평가



6. 개발 발전 및 향후 계획

6.1 모델 고도화 및 최적화

- **앙상블 기법 고도화:** 기존 Random Forest 단일 모델에서 XGBoost, LightGBM 등 부스팅 계열 모델을 결합한 Stacking 앙상블을 적용하여 예측 성능 및 정밀도 향상을 도모하고자 함
- **딥러닝(Deep Learning) 모델 확장:** 정형 데이터 기반 분석을 넘어, 상담 기록 텍스트를 활용한 NLP 모델을 결합한 멀티모달(Multi-modal) 분석 구조를 연구하여 고립 위험 예측의 정교화를 추진
- **설명 가능한 인공지능(XAI) 강화:** SHAP(Shapley Additive Explanations) 기반 해석 결과를 웹 애플리케이션에 시각화하여, 상담사가 고위험군 판단 근거를 직관적으로 이해할 수 있도록 지원

6.2 서비스 확장 및 현장 적용

- **모바일 앱(Mobile App) 개발:** 청년들이 자신의 상태를 자가진단(Self-Check)할 수 있는 모바일 버전 출시 및 접근성 강화
- **상담 시스템 연동:** 보건복지부 및 지자체 청년 상담 시스템(API)과 연동하여 고위험군 자동 발굴 및 상담 예약 자동화 구현
- **데이터 추적 파이프라인 구축:** 사용자의 진단 결과와 실제 상담 결과를 피드백(Feedback Loop) 받아 모델을 주기적으로 재학습(Retraining)하는 MLOps 체계 마련

<느낀 점>

이번 청년 고립·은둔 위험군 예측 모델 개발 프로젝트를 통해 데이터가 사회 문제 해결에 실질적으로 기여할 수 있음을 체감했습니다. 5,513명의 데이터를 분석하며 교류 빈도와 경제 수준이 고립 위험을 설명하는 핵심 요인임을 도출함으로써, 추상적으로 인식되던 문제를 데이터 기반의 분석 과제로 구체화할 수 있었습니다.

또한, 전체의 8.8%에 불과한 고위험군을 탐지하기 위해 불균형 데이터 처리와 F1-Score 중심의 평가 전략을 적용하며, 정확도보다 실제 활용 가능성을 고려한 모델 설계의 중요성을 이해하게 되었습니다. 본 프로젝트를 통해 기술적 역량뿐 아니라, 데이터가 사회적 안전망을 강화하는 도구가 될 수 있다는 책임감을 함께 갖추게 되었습니다. 앞으로도 기술을 통해 사회 안전망을 강화하는 데 기여하고 싶습니다.