

2025년도 머신러닝 개인 프로젝트

# AI개발 수행내역서

|     |                                                    |
|-----|----------------------------------------------------|
| 과제명 | 청년 고립·은둔 위험군 탐지를 위한 AI 예측<br>모델 및 의사결정 지원 웹 서비스 구축 |
| 담당자 | 신민서                                                |

2025년 12 월 30 일

## AI개발 수행내용

사업과제 : 청년 고립·은둔 위험군 탐지를 위한 AI 예측 모델 및 의사결정 지원 웹 서비스 구축

### 1. 개요 및 현황

#### 1.1 추진배경 및 목적

- 1인가구 급증 및 사회적 안전망 약화로 청년층의 고립 위험이 구조적으로 심화되고 있으며, 고독사 등 사회적 문제로 연결될 우려가 있음
- 최근 '일자리 밖' 청년이 160만 명에 육박하는 등 고용 부진과 장기 미취업이 청년의 자존감 하락 및 사회적 단절(은둔)을 촉발하는 핵심 요인으로 작용
- 본 과제에서는 청년 실태 데이터를 활용해 고립·은둔 위험군을 조기에 판별할 수 있는 AI 예측 모델을 개발하여, 선제적 발굴 및 맞춤형 지원 정책의 근거를 마련하고자 함

#### 1.2 과제 범위

| 과제구분 |                          | 내용                                                                   |
|------|--------------------------|----------------------------------------------------------------------|
| AI   | AI 기반 고립·은둔 위험군 예측 모델 개발 | 원시 데이터(서울시 실태조사 5,513명) 수집 및 데이터셋 구축                                 |
|      |                          | 데이터 전처리(결측치, 이상치, 인코딩) 및 상관관계 분석 (EDA 도구 활용)                         |
|      |                          | 예측 모델 선정(Random Forest, Logistic Regression 등) 및 학습                  |
|      |                          | Accuracy, ROC-AUC, Precision, Recall, F1-Score<br>평가지표를 활용한 모델 성능 평가 |
| 시각화  | 예측 결과 시각화 및 웹 시스템 구축     | 예측 실행 웹앱 프로토타입 구축 (Streamlit 활용)                                     |
|      |                          | 개인별 위험도 점수 및 위험 수준(고/중/저) 시각화                                        |
|      |                          | 모델 성능(ROC 곡선, 혼동행렬) 및 특성 중요도(Feature Importance) 시각화                 |
| 테스트  | 모델 검증 및 시스템 테스트          | 테스트 데이터셋(20%)을 활용한 일반화 성능 검증                                         |
|      |                          | 웹 애플리케이션 기능 테스트 및 사용성 점검                                             |

#### 1.3 과제 추진 방법

##### 1) 구축 대상 선정 기준

- 데이터 접근성 및 신뢰성
  - 서울시 공식 조사기관에서 수집한 신뢰할 수 있는 청년 표본 데이터 활용
  - 5,513명의 대규모 표본으로 통계적 신뢰성 및 모델 일반화 가능성 확보
  - 전문가 상담 및 진단을 통해 고립·은둔 여부를 객관적으로 분류한 라벨 데이터 확보

### ○ 모델링 효율성

- \*\*클래스 불균형(고위험 8.8% vs 저위험 91.2%)\*\*이 존재하지만 극단적이지 않아 모델 최적화(SMOTE, Class Weight 등) 용이
- 결측치가 특정 변수에 집중 되어 있어 일관된 처리 방안 수립 및 적용 가능
- 변수 간 다중공선성이 낮아, 독립변수의 개별 영향력을 명확히 파악하는 안정적인 모델 학습 기대


### ○ 실무 활용도 및 경제성

- 청년 고립·은둔 문제 해결을 위한 정책 입안 및 현장 개입의 과학적 근거 제공
- 상담 전문가의 \*\*의사결정 지원(Decision Support)\*\*으로 조기 발굴 및 개입 효율성 향상
- 고위험군 자동 선별(Screening)을 통한 비용 절감 및 사각지대 해소 효과

## 2) AI 예측 분석모델 적용 대상

| 구분          | 수집 데이터                                                                                                                                                     | 예측모델인자(독립변수)                                                                                                                                                               | AI예측 분석 대상                                                                                                                                                                |
|-------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 청년<br>고립·은둔 | <ul style="list-style-type: none"> <li>- 고립·은둔 여부 라벨 데이터 (5,513명)</li> <li>- 심리·사회·경제 특성</li> <li>- 인구통계 정보 (성별, 나이 등)</li> <li>- 가구 특성 및 주거 환경</li> </ul> | <ul style="list-style-type: none"> <li>- A11 (교류 빈도)</li> <li>- A6 (사회경제 수준)</li> <li>- A1 (노동여부)</li> <li>- DQ2 (직업)</li> <li>- A5 (식사 횟수)</li> <li>- SQ2 (나이)</li> </ul> | <ul style="list-style-type: none"> <li>- 개별 고립·은둔 위험도(Risk Score) 산출</li> <li>- 고위험군 조기 발굴 및 등급화(High/Mid/Low)</li> <li>- 주요 변수(식사 횟수, 교류 빈도 등)와 고립 간의 상관관계 분석</li> </ul> |

## 3) AI 분석모델 구축 프로세스



## 연구개발 주요 결과물

### 2. 데이터 수집 및 개요

#### 2.1 데이터 출처

- 출처: <https://data.seoul.go.kr/dataList/OA-22347/F/1/datasetView.do>
- 대상: 서울 거주 만 19~39세 청년 및 고립·은둔 청년 당사자
- 목적: 청년의 생활 실태 및 고립·은둔 위험 요인을 분석하여 AI 기반 예측 모델 개발

#### 2.2 데이터 구성 및 클래스 분포

- 총 데이터 수량: 5,513명
- 저위험군 (미해당, 0): 5,027명 (91.2%)
- 고위험군 (고립·은둔, 1): 486명 (8.8%)

#### 분석

고위험군이 전체의 약 8.8%를 차지하여 클래스 불균형(Imbalanced Data)이 존재함. 이를 해결하기 위해 모델 학습 시 Class Weight 조정 및 F1-Score 중심의 성능평가를 수행함

#### 2.3 Features 및 전처리 구조

청년의 고립·은둔에 영향을 미치는 변수를 인구통계, 심리상태, 경제활동, 생활습관 등으로 분류하여 분석

- 전처리 전: 21개 변수 (결측치 34,434개 존재)
- 전처리 후: 44개 변수 (원-핫 인코딩 적용 후, 결측치 0개)

```
>> 변수 타입 분류:
  ● 명목형(순서 없음): A1, DQ2, DQ3, DQ5, B5_1, B7, B8 → 원-핫 인코딩 필수
  ● 서수형(순서 있음): SQ1, SQ2_X, SQ6_R, A5, A6, B2_R, A11 → 그대로 사용
  ● 더미형(다중선택): A4_1~A4_7 → 0/1 그대로

  [✓] SQ1 | 결측치: 0 ( 0.00%)
  [✓] A1 | 결측치: 0 ( 0.00%)
  [✓] SQ2_X | 결측치: 0 ( 0.00%)
  [✓] SQ6_R | 결측치: 0 ( 0.00%)
  [✓] A5 | 결측치: 80 ( 1.45%)
  [✓] A6 | 결측치: 80 ( 1.45%)
  [✓] B2_R | 결측치: 160 ( 2.90%)
  [✓] DQ2 | 결측치: 80 ( 1.45%)
  [✓] DQ3 | 결측치: 159 ( 2.88%)
  [✓] DQ5 | 결측치: 0 ( 0.00%)
  [✗] DQ5_1 | 결측치: 2011 (36.48%)
  [✓] A11 | 결측치: 159 ( 2.88%)
  [✗] A4_1 | 결측치: 679 (12.32%)
  [✗] A4_2 | 결측치: 5176 (93.89%)
  [✗] A4_3 | 결측치: 5354 (97.12%)
  [✗] A4_4 | 결측치: 5448 (98.82%)
  [✗] A4_5 | 결측치: 5478 (99.37%)
  [✗] A4_6 | 결측치: 4318 (78.32%)
  [✗] A4_7 | 결측치: 5252 (95.27%)
  [✓] B7 | 결측치: 0 ( 0.00%)
  [✓] B8 | 결측치: 0 ( 0.00%)
```

## 1) 변수 타입별 처리 전략

| 변수타입           | 처리 방식                         | 해당 변수                                               |
|----------------|-------------------------------|-----------------------------------------------------|
| 명목형<br>(순서 없음) | 원-핫 인코딩<br>(One-Hot Encoding) | A1(노동여부), DQ2(직업), DQ3(혼인상태), DQ5(주택형태), B8(식사횟수) 등 |
| 서수형<br>(순서 있음) | 수치형 유지<br>(Label Encoding)    | SQ1(성별), SQ2(나이), A5(경제수준), A11(교류빈도)               |
| 더미형<br>(다중선택)  | 0/1 그대로 사용                    | A4_1 ~ A4_7 (소득원 정보)                                |

## 2) 결측치(Missing Value) 처리 내역

- 소득원(A4): 미가입 항목은 '없음(0)'으로 간주하여 대체
- 주요 변수(A5, A6, A11 등): 데이터 분포의 안정성을 위해 \*\*중앙값(Median)\*\*으로 대체
- 범주형 변수(DQ2(직업), DQ3(혼인상태)): 최빈값(Mode)으로 대체하여 데이터 왜곡 최소화

### 4.1 소득원 결측치 처리: 0으로 대체

### 4.2 결측치 처리 (수치형/범주형 구분):

- ✓ A5: 중앙값 3.00 으로 대체
- ✓ A6: 중앙값 2.00 으로 대체
- ✓ B2\_R: 중앙값 2.00 으로 대체
- ✓ DQ2: 중앙값 1.00 으로 대체
- ✓ DQ3: 중앙값 2.00 으로 대체
- ✓ DQ5\_1: 중앙값 1.00 으로 대체
- ✓ A11: 중앙값 5.00 으로 대체

### 4.3 원-핫 인코딩 (명목형 변수):

대상 변수: DQ2, DQ3, DQ5, A1, B8, B2\_R, B7

### 3. 데이터 학습 및 모델정의

#### 3.1 데이터 분할 및 스케일링

##### 1) Train/Test Split (학습 데이터 분할)

모델의 일반화 성능 검증을 위해 전체 데이터를 학습(80%) : 테스트(20%) 비율로 분할 하였으며, 클래스 불균형을 유지하기 위해 Stratified Split 방식을 적용함.

| 구분             | 샘플 수   | 고위험군 수 | 고위험군 비율 |
|----------------|--------|--------|---------|
| 학습 데이터 (Train) | 4,410명 | 389명   | 8.8%    |
| 테스트 데이터 (Test) | 1,103명 | 97명    | 8.8%    |
| 합계             | 5,513명 | 486명   | 8.8%    |

##### 2) 데이터 스케일링 (StandardScaler)

변수 간 스케일 차이로 인한 학습 편향을 방지하기 위해 StandardScaler를 적용함.

- 학습 데이터: fit() 수행하여 평균(mean)과 표준편차(std) 계산
- 테스트 데이터: transform()만 적용하여 데이터 누수(Data Leakage) 방지

#### 3.2 모델 학습 및 하이퍼파라미터 튜닝

##### 1) 후보 모델 선정 및 학습

고립·은둔 위험군 예측을 위해 2가지 알고리즘을 비교 학습함

| 모델명                 | 알고리즘 유형              |
|---------------------|----------------------|
| Logistic Regression | 선형 분류 모델 (해석 가능성 높음) |
| Random Forest       | 앙상블 모델 (비선형 패턴 포착)   |

##### 2) 하이퍼파라미터 튜닝 (GridSearchCV)

Random Forest 모델의 성능 최적화를 위해 \*\*GridSearchCV(5-Fold Cross Validation)\*\*를 수행하여 최적 파라미터를 탐색함

- 최적 F1-Score: 0.5078
- 튜닝 기준: Precision과 Recall의 균형을 고려한 F1-Score 최대화

| 파라미터              | 최적값 | 의미            |
|-------------------|-----|---------------|
| n_estimators      | 150 | 의사결정나무 개수     |
| max_depth         | 20  | 트리 최대 깊이      |
| min_samples_split | 10  | 노드 분할 최소 샘플 수 |
| min_samples_leaf  | 2   | 리프 노드 최소 샘플 수 |

### 3.3 모델 성능 비교

#### 1) 최종 성능 평가 (테스트 데이터 기준)

3가지 모델(로지스틱 회귀, 랜덤 포레스트 기본, 랜덤 포레스트 최적화)을 학습한 후 테스트 데이터 (1,103명)로 평가한 결과는 다음과 같음

| 모델명                                 | Accuracy     | ROC-AUC      | Precision    | Recall       | F1-Score     |
|-------------------------------------|--------------|--------------|--------------|--------------|--------------|
| Logistic Regression                 | 0.786        | 0.846        | 0.254        | <b>0.742</b> | 0.379        |
| Random Forest (Basic)               | <b>0.928</b> | 0.855        | <b>0.765</b> | 0.268        | 0.397        |
| Random Forest (Best - F1 Optimized) | 0.904        | <b>0.873</b> | 0.464        | 0.598        | <b>0.523</b> |

#### 2) 모델별 특성 분석

- **Logistic Regression:** Recall이 높아(74.2%) 고위험군을 많이 탐지하지만 Precision(정밀도)가 낮아 오탐 (False Positive)이 많음. 스크리닝(1차 선별)용으로 적합
- **Random Forest (Basic):** Accuracy와 Precision은 우수하나 Recall이 낮아(26.8%) 고위험군의 73%를 놓침
- **Random Forest (Best - F1 Optimized):** Precision-Recall(정밀도) 균형이 가장 우수하며 ROC-AUC도 최고(0.873) -> (최종 선정 모델)

3.4 특성 중요도 분석 (Feature Importance)


최적화된 Random Forest 모델을 통해 고립·은둔에 가장 큰 영향을 미치는 변수를 분석한 결과, 상위 10개 변수는 다음과 같음

| 순위 | 변수명                 | 중요도   | 해석                          |
|----|---------------------|-------|-----------------------------|
| 1  | A11(교류 빈도)          | 0.155 | 타인과의 만남 횟수 ↓ → 고립 위험 ↑      |
| 2  | A6 (사회경제 수준)        | 0.145 | 주관적 경제 수준 ↓ → 고립 위험 ↑       |
| 3  | A1_3 (노동 여부: 미취업)   | 0.119 | 지난주 일하지 않음 → 사회적 단절 위험      |
| 4  | DQ2_10.0 (직업: 무직)   | 0.069 | 현재 아무런 일을 하지 않음 → 고립 위험 ↑   |
| 5  | A5 (식사 횟수)          | 0.063 | 식사 횟수 ↓ → 고립 위험 ↑           |
| 6  | SQ6_R (동거 가구원 수)    | 0.041 | 1인 가구 또는 가족 내 고립 → 위험 ↑     |
| 7  | SQ2_X (나이)          | 0.034 | 특정 연령대 → 고립 취약              |
| 8  | DQ3_2.0 (혼인 상태: 미혼) | 0.032 | 미혼 상태(가족 형성 부재) → 정서적 지지 ↓  |
| 9  | A4_1 (소득원: 본인 소득)   | 0.030 | 본인 소득 의존도가 높으나 불안정 → 경제적 고립 |
| 10 | DQ5_4 (주택형태: 아파트)   | 0.021 | 폐쇄적 주거 환경(아파트 등) → 이웃 교류 ↓  |

4. 모델 평가 및 분석 결과 시각화

4.1 모델 성능 종합 평가 (ROC Curve Comparison)

모델별 성능을 비교하기 위해 ROC(Receiver Operating Characteristic) 곡선과 AUC(Area Under Curve) 점수를 시각화함






### <분석 결과>

- Random Forest (Best) 모델의 AUC가 0.873으로 가장 높게 나타남.
- Logistic Regression (AUC 0.846) 대비 곡선이 왼쪽 상단(좌상향)에 더 근접하여, 예측 정확도와 안정성이 우수함을 입증함.
- 점선(Random Guess, AUC 0.5)과 확연한 차이를 보이며 유의미한 예측 모델임이 확인됨.

## 4.2 혼동행렬 분석 (Confusion Matrix)


테스트 데이터(1,103명)에 대한 실제값과 예측값의 일치 여부를 혼동행렬로 시각화하여 정밀하게 분석



- Logistic Regression (좌측): 고립(Isolated)을 72명 잘 맞췄으나, 일반(Normal)을 고립으로 잘못 예측한 경우(오탐, FP)가 211명으로 많음 → 과잉 탐지 경향
- Random Forest Best (우측): 오탐(FP)이 67명으로 대폭 감소(211→67)하였으며, 고립군 예측(TP)도 58명으로 준수한 수준을 유지함
- 결론: 오탐을 줄여 실제 현장 개입의 효율성을 높이기 위해 Random Forest 모델이 더 적합함

### 4.3 핵심 영향 요인 분석 (Feature Importance)


Random Forest 모델이 고립·은둔을 판단할 때 가장 중요하게 고려한 \*\*상위 10개 변수 (Top 10 Features)\*\*를 도출함



- 1순위 A11 (교류 빈도): 타인과의 만남 횟수가 가장 결정적인 요인으로 나타남
- 2순위 A6 (사회경제 수준): 주관적인 경제 수준 인식이 고립에 큰 영향을 미침
- 3순위 A1\_3 (노동 여부: 무직): 경제활동(취업) 여부가 사회적 단절과 직결됨
- 시사점: 단순히 '성격'의 문제가 아니라 \*\*경제적 요인(A6, A1)\*\*과 \*\*사회적 관계망(A11)\*\*이 고립을 유발하는 구조적 원인임을 데이터로 입증함

### 4.4 고립·은둔 집단 특성 분석 (A11 분포)

가장 중요한 변수인 \*\*A11(교류 빈도)\*\*의 데이터 분포를 고위험군(Isolated)과 저위험군(Normal)으로 나누어 비교함




- Red (Isolated): 고위험군은 A11 값이 '0' 근처에 극도로 집중되어 있음. (거의 만나지 않음)
- Blue (Normal): 저위험군은 A11 값이 0보다 크고 넓게 퍼져 있어, 비교적 활발하고 다양한 교류 패턴을 보임
- 해석: "교류가 거의 없는 상태(0)"가 고립:은둔을 식별하는 가장 강력한 \*\*시그널(Signal)\*\*임이 시각적으로 확인됨

## 5. 웹기반 예측 시스템 (Streamlit Dashboard)

### 5.1 시스템 개요

- 청년 고립:은둔 위험군을 실시간으로 진단하고 시각화하는 웹기반 대시보드 시스템을 Streamlit 프레임워크로 개발함
- 사용자 입력 없이도 모든 분석 결과를 한눈에 확인할 수 있으며, 특히 개인별 위험도 예측 기능은 상담 현장에서 직접 활용 가능



## 📁 프로젝트 개요

### 🎯 목표

서울시의 고립·은둔 위험군을 머신러닝으로 예측하고 영향 요인을 분석합니다.

### 📊 데이터

- 출처: 서울시 고립·은둔 실태 조사
- 샘플: 5,513명
- 특성: 44개

### 🧠 모델

- RandomForest (최고 성능) - 높은 정확도, 특성 중요도 분석
- LogisticRegression - 해석성 우수, 확률 기반 예측

### 🔍 주요 기능

- 👤 개인 위험도 진단 - 사용자 입력으로 위험도 예측
- 📊 모델 성능 - 상세한 성능 비교
- 📈 특성 분석 - 핵심 영향 요인 파악
- 🖼️ 시각화 - ROC Curve, Confusion Matrix 등

### ⚡ 빠른 참조

타겟 변수:

- 고위험군 (1)
- 저위험군 (0)

평가 지표:

- Accuracy
- ROC-AUC
- Precision
- Recall
- F1-Score

사용 변수:

- A1: 노동 여부
- DQ2: 직업
- A11: 교류 횟수
- A5: 식사 횟수
- A6: 사회경제 수준
- SQ6\_R: 동거 인원

## 5.2 핵심 입력 변수 선정 (사용자 편의성 고려)

AI 모델은 총 44개의 정밀한 변수를 학습하여 높은 예측 성능을 확보하였으나, 실제 대국민 웹 서비스(Web App)에서는 사용자의 입력 부담을 줄이고 접근성을 높이기 위해 특성 중요도(Feature Importance)가 높은 상위 7개 핵심 변수를 선별하여 입력값으로 활용함.

| 순번 | 변수명   | 변수 설명              | 입력 방식 (UI)  |
|----|-------|--------------------|-------------|
| 1  | A11   | 교류 빈도(타인과의 만남 횟수)  | 슬라이더 / 선택지  |
| 2  | A6    | 사회경제 수준(주관적 인식)    | 선택트박스 / 선택지 |
| 3  | A1    | 노동 여부(지난주 경제활동 유무) | 선택트박스 / 선택지 |
| 4  | DQ2   | 직업 상태(현재 고용 형태)    | 선택트박스 / 선택지 |
| 5  | A5    | 식사 횟수(일 평균 끼니 수)   | 선택트박스 / 선택지 |
| 6  | SQ6_R | 동거 가구원 수           | 슬라이더 / 선택지  |
| 7  | SQ2_X | 나이                 | 라디오버튼/ 선택지  |

## 5.3 예측 서비스 프로세스

- 사용자 입력: 웹페이지에서 위 6가지 핵심 질문에 답변
- AI 모델 추론: 입력되지 않은 나머지 변수는 전체 데이터셋의 \*\*대표값(최빈값/중앙값)\*\*으로 자동 보정하여 모델에 주입
- 결과 산출: 전체 44개 변수 기반으로 학습된 모델이 고립·은둔 위험 확률(%) 계산
- 피드백 제공: 위험도 등급(고/중/저) 및 맞춤형 지원 정책 안내

## 5.4 개인 위험도 예측 (Prediction)

- 목적: 실제 상담 현장에서 신규 청년의 고립 위험도를 즉시 진단

### 개인 위험도 진단 6Q

6가지 주요 정보를 입력하면 AI가 고립-은둔 위험도를 판정합니다.

- **저위험군**: 사회활동이 활발하고 건강한 생활습관
- **중위험군**: 일부 위험 요소 존재 - 개선 필요
- **고위험군**: 사회적 고립 경향이 높음 - 전문가 상담 권장

#### 나이 (연령대)

SQ2\_X: 나이 (5세 단위 연령대)

- ☐ 만 19~24세  
☒ 만 25~29세  
☐ 만 30~34세  
☐ 만 35~39세

#### 경제 활동

A1: 한 주 동안 1시간 이상의 노동 여부

☒ 일을 하였다

DQ2: 현재 직업

정규직(상용직)

#### 사회 활동

A11: 지난 2주 동안 사람들의 교류 횟수 ★

0

교류 횟수

0회

#### 생활 습관

A5: 하루 동안의 식사 횟수

4끼 이상



A6: 자신의 사회경제적 수준

매우 부족함

#### 가구 구성

SQ6\_R: 함께 살고 있는 사람 수 (자신 포함)

3

 (3명)

동거 인원

3명

 위험도 판정하기

## 💡 권고사항 및 해석

### ● 고위험군 (고위험 확률: 55.7%)

현재 상태: 전문 기관 상담이 필요합니다 🚨


권고 사항:

- 🏠 서울시 고립·은둔 관련 부서에 연락하기
- 👨‍👩‍👧 가족이나 신뢰할 수 있는 사람과 대화하기
- 🏥 정신 건강 검진 받기
- 📅 직업 훈련 또는 상담 프로그램 참여
- 🌐 사회 복귀 프로그램 정보 수집

주의: 이 진단은 의료 전문가의 진단을 대체할 수 없습니다.

## 📊 위험도 시각화

고립·은둔 위험도 평가



## 6. 개발 발전 및 향후 계획

### 6.1 모델 고도화 및 최적화

- **앙상블 기법 고도화:** 기존 Random Forest 단일 모델에서 XGBoost, LightGBM 등 부스팅 계열 모델을 결합한 Stacking 앙상블을 적용하여 예측 성능 및 정밀도 향상을 도모하고자 함
- **딥러닝(Deep Learning) 모델 확장:** 정형 데이터 기반 분석을 넘어, 상담 기록 텍스트를 활용한 NLP 모델을 결합한 멀티모달(Multi-modal) 분석 구조를 연구하여 고립 위험 예측의 정교화를 추진
- **설명 가능한 인공지능(XAI) 강화:** SHAP(Shapley Additive Explanations) 기반 해석 결과를 웹 애플리케이션에 시각화하여, 상담사가 고위험군 판단 근거를 직관적으로 이해할 수 있도록 지원

### 6.2 서비스 확장 및 현장 적용

- **모바일 앱(Mobile App) 개발:** 청년들이 자신의 상태를 자가진단(Self-Check)할 수 있는 모바일 버전 출시 및 접근성 강화
- **상담 시스템 연동:** 보건복지부 및 지자체 청년 상담 시스템(API)과 연동하여 고위험군 자동 발굴 및 상담 예약 자동화 구현
- **데이터 추적 파이프라인 구축:** 사용자의 진단 결과와 실제 상담 결과를 피드백(Feedback Loop) 받아 모델을 주기적으로 재학습(Retraining)하는 MLOps 체계 마련

### <느낀 점>

이번 청년 고립·은둔 위험군 예측 모델 개발 프로젝트를 통해 데이터가 사회 문제 해결에 실질적으로 기여할 수 있음을 체감했습니다. 5,513명의 데이터를 분석하며 교류 빈도와 경제 수준이 고립 위험을 설명하는 핵심 요인임을 도출함으로써, 추상적으로 인식되던 문제를 데이터 기반의 분석 과제로 구체화할 수 있었습니다.

또한, 전체의 8.8%에 불과한 고위험군을 탐지하기 위해 불균형 데이터 처리와 F1-Score 중심의 평가 전략을 적용하며, 정확도보다 실제 활용 가능성을 고려한 모델 설계의 중요성을 이해하게 되었습니다. 본 프로젝트를 통해 기술적 역량뿐 아니라, 데이터가 사회적 안전망을 강화하는 도구가 될 수 있다는 책임감을 함께 갖추게 되었습니다. 앞으로도 기술을 통해 사회 안전망을 강화하는 데 기여하고 싶습니다.